

ALAPFOGALMAK

- a formális nyelv olyan matematikai és informatikai fogalom, amely véges hosszúságú szavak halmazát írja le
 - ezek a szavak karakter stringek vagy jelsorozatok lehetnek, és egy előre meghatározott ábécéből generálhatók
 - az ábécé az a halmaz, amelyből a szavak betűi vagy szimbólumai származnak
- a formális nyelvek kutatása révén megérthetjük a programozási nyelvek alapjait, a számítógépes nyelvfeldolgozás (NLP) módszereit, valamint az automatikus szövegelemzés és fordítás elveit
- Mivel foglalkozik a formális nyelvek?
 - a formális nyelvek elmélete szimbólumsorozatok halmazaival foglalkozik
 - Célja: véges, tömör, leírást adni az ilyen halmazoknak

Σ (ábécé)

- az ábécé az a halmaz, amelyből a szavak betűi vagy szimbólumai származnak, azaz szimbólumoknak, pontosabban **a terminálisoknak egy tetszőleges véges, nem üres halmaza**
 - $\Sigma = \{ a, b \}$
 - ehhez tartozó szavak: ϵ , a, b, ab, aabb, abba, abb, ...
- Iterált ábécé: Σ^*
 - az összes az ábécéhez hozzátartozó szó, még az üres szó is
- Σ^+ az összes hozzátartozó szó, kivétel az üres szó
 - $\Sigma^+ = \Sigma^* - \{ \epsilon \}$

w (szó)

- ábécé elemeivel képzett véges sorozat
- üres szó (ϵ - epszilon)
- w szó hossza: $|w|$
- w szó megfordítása: w^R
 - tehát $(w_1 w_2)^R = w_2^R w_1^R$, minden w_1, w_2 -re ami elem Σ^* -nak
- konkatenáció w_1 és w_2 szó egybefűzése a $w_1 w_2$
- prefix és szuffix (aab esetén)
 - prefix: ϵ , a, aa, aab
 - szuffix: aab, ab, b, ϵ
- a^n , azt jelenti, hogy a karakter egymásután n -szer jelenik meg

Formális nyelv (L)

- tetszőleges részhalmaza Σ^* -nak (iterált abécének)
 - Σ feletti nyelv
- szavak egy véges vagy végtelen halmaza
 - ha véges szóból áll akkor véges nyelv, ha nem véges akkor végtelen nyelv
- L^* , az L nyelv iteráltja, mindig benne van az ε
- L^+ , is L nyelv iteráltja csak nincs benne az ε

Generatív nyelvtan (G)

- nyelvek generálására, megadására szolgáló eszköz
 - nyelv a szavak halmaza, a nyelvtan meg szabályok és struktúrák alapján, leírja, hogy a nyelvet milyen szavak és mondatok alkotják
- $G = (N, \Sigma, S, P)$
 - N: nemterminális szimbólumok (A, B, S, stb) véges, nem üres halmaza
 - **nemterminálisok:** olyan “változók” melyekre nyelvi szabályok alkalmazhatók, a végső nyelvtanban nem jelennek meg, a kialakítására használjuk csak
 - ezek eszközök, míg a terminálisok az alapanyagok
 - Σ (szigma) abécé, mely a terminálisok (a, b, c, d) véges, nem üres halmaza
 - **terminálisok:** “kimeneti” betűk (szimbólumok végső formái)
 - N és Σ metszete üres
 - S kezdő nemterminális, S eleme N-nek
 - P: levezetési, átírási (produkciós) szabályok véges halmaza
 - szabály: $S \rightarrow aS \mid bS \mid a \mid b$
 - egy szabály bal oldalán több nemterminális, míg a jobb oldalán bármi állhat
 - pl "ab" megkapásához a következő levezetés kell: $S \Rightarrow aS \Rightarrow ab$

Levezetés és Generált nyelv

- közvetlen levezetés: $x \Rightarrow y$
 - akkor van róla szó ha a szabályok segítségével egy mondatformából **egyetlen lépésben** egy másikat kapunk
- levezetés a közvetlen levezetések véges sorozata
- $x \Rightarrow^n y$, azaz n lépésből jut oda a levezetés
- $x \Rightarrow^+ y$, azaz legalább egy lépés
- $x \Rightarrow^* y$, azaz valamennyi (akár 0) lépés
- Generált nyelv ($L(G)$)
 - azon terminális szavak (Σ feletti szavak) halmaza, amelyek a kezdőszimbólumból (S) levezethetők

Chomsky hierarchia (ejtsd: csompszki)

- a nyelvtanokat szabályaik (P) formája alapján 4 osztályba soroljuk:

1. Reguláris nyelvek (3-as típus):

- szabály **bal oldalán pontosan egy nemterminális**, és a **jobb oldalán legfeljebb egy nemterminális** van és ha van is akkor az a jobb végén van (jobb lineáris)
 - ha P-ben minden szabály $A \rightarrow xB$, vagy $A \rightarrow x$ alakú
 - példa:
 $S \rightarrow aA$
 $A \rightarrow bS$
 $A \rightarrow b$
 $B \rightarrow bSS$ –HIBA nem jó (2 nemterminális)
- ezek a legegyszerűbb nyelvek
- minden reguláris nyelv egyben környezetfüggetlen is

2. Környezetfüggetlen nyelvek (2-es típus):

- a szabályok alakja $A \rightarrow w$, ahol $A \in N$ és $w \in (N \cup \Sigma)^*$
- itt a **bal oldalon mindig csak egyetlen nemterminális állhat**, függetlenül a környezetétől, **a jobb oldalon állhat akár több nemterminális is**
 - azért környezetfüggetlenek, mert a szabály bal oldalán álló nemterminálist (A) bárhol és bármikor átírhatjuk a szabály jobb oldalán, függetlenül attól, hogy milyen jelek veszik körül a mondatformában (szövegkörnyezetben)
 - hogy egy 'B' betűt 'A' betűre cserélhetünk, akkor ez a cserélhetőség minden környezetben érvényes, függetlenül attól, hogy a 'B' betű milyen szimbólumok között helyezkedik el
- Példa:
 $A \rightarrow wA$ (jó)
 $A \rightarrow BwA$ (Jó)
 $AA \rightarrow w$ (nem jó)

3. Környezetfüggő nyelvek (1-es típus)

- a szabályok alakja $uXv \rightarrow uv$, ahol $X \in N$, és a hossza nem csökkenhet (kivéve az üres szó generálását)

4. Általános nyelvek (0-ás típus)

- nincs megkötés a szabályokra, csak annyi, hogy a bal oldalon lennie kell legalább egy nemterminálisnak
- Az **osztályok között valódi tartalmazás** áll fent
 - $L_3 \subset L_2 \subset L_1 \subset L_0$
 - ebből következik, például az, hogy minden reguláris nyelv egyben környezetfüggetlen is, és minden környezetfüggetlen nyelv környezetfüggő is, stb.

REGULÁRIS NYELVEK

A legegyszerűbb nyelvcsalád (3-as típusú a Chomsky hierarchiában). Egy nyelv akkor reguláris, ha generálható reguláris nyelvtannal, felismerhető véges automatával, vagy leírható reguláris kifejezéssel.


Véges automáták

- a véges automata egy olyan absztrakt gép, amely véges sok belső állapottal rendelkezik, és a bemeneti szót betűnként olvassa balról jobbra
 - az állapotok között átmenetek vannak, melyek a bemeneti jelek függvényében aktiválódnak, így egy adott állapotban marad még nem érkezik olyan jel, ami alapján neki át kell lépnie egy másik állapotba
- akkor ismer fel egy input szót, ha a karakterjein végig ugrálva végállapotba jutunk
- $M = (Q, \Sigma, \delta, q_0, F)$
 - Q : állapotok halmaza (nem üres, véges halmaz)
 - pl: $Q = \{q_0, q_1, q_2\}$
 - Σ : input ábécé
 - δ (delta): egy átmenet függvény
 - megadja, hogy egy adott állapotból (csúcsból) egy adott terminális (betű) hatására hova lép az automata
 - pl: $\delta(q, a) = p$, tehát q csúcs "a" input hatására p csúcsba megy
 - q_0 : kezdő állapot, eleme Q -nak
 - F : végállapotok halmaza, részhalmaza Q -nak
- minden lépésben az automata beolvassa a következő input szimbólumot, és átmegy egy olyan állapotba, amelyet az átmeneti függvény meghatároz az adott aktuális input szimbólumra, és azon állapotról vonatkozóan, amelyben az automata az adott pillanatban van
 - az input szó felfogható úgy, mint egy cellákra osztott szalag, aminek minden helye egy szimbólumot tartalmaz. Kezdetben az A véges automata a q_0 kezdőállapotban van, és az olvasófej az input szalagon lévő u szó első betűjét dolgozza fel. Ezután a véges automata lépések sorozatát hajtja végre, így olvassa végig az u szót, betűről betűre haladva
- táblázattal is megadható (első sor a bemeneti, *-al meg a végállapotokat jelölhetjük)

Állapot/Input	a	b
-> q_0	q_1	q_2
q_1	q_0	q_2
* q_2	q_2	q_2

- **Determinisztikus véges automata (DFA)**

- egyirányú ($\delta: Q \times \Sigma \rightarrow Q$)
 - minden állapotból minden bemenő jelre pontosan egy átmenet (él) létezik (ergó nincsenek benne ugyanarra a jelre, betűre elágazások)
- a gép útja egyértelmű (függvény)




$$L = \{0^*1(1 \mid 00 \mid 01)^*\}$$

Vagy egyszerűbb szavakkal megfogalmazva: Minden olyan $\{0, 1\}$ feletti szó, amely tartalmaz legalább egy 1-et, és NEM 0-ra végződik úgy, hogy előtte páratlan darab 0-s áll a legutolsó 1-es óta. Sokkal intuitívabb, ha úgy nézzük: a szóban kötelezően lennie kell legalább egy 1-esnek, és az utolsó 1-es után csak páros számú karakter állhat, ha az utolsó karakter történetesen 0-s (különben elakadna q_3 -ban).

• Nemdeterminisztikus véges automata (NFA)

- többirányú ($\delta: Q \times \Sigma \rightarrow P(Q)$, ahol $P(Q)$ a Q hatványhalmaza)


- egy állapotból egy jel hatására akár több állapotba is átléphet (több él futhat ki belőle, ilyenkor a jelenlegi állapotot mint halmaz kezeli), vagy egyáltalán nem létezik átmenet



$$L = \{(0 | 1)^* 0\}$$

Vagyis a 0 és 1 feletti összes olyan szó, amely 0-ra végződik.

- mikor több irányba léphet akkor úgyis tesz és akkor lesz elfogadva a bementi szó, ha legalább az egyik irányba elfogadó állapotra lép mikor végez



- lehet több kezdeti állapota is
- akkor teljes ha nincs elakadás, azaz mindig van legalább egy átmenete
 - minden nemdeterminisztikus automata teljesre hozható
- egy nyelv akkor és csak akkor ismerhető fel nemdeterminisztikus automatóval, ha felismerhető determinisztikus automatóval
- minden nemdeterminisztikus véges automatához szerkeztethető vele ekvivalens determinisztikus véges automata

- tehát az NFA és DFA kifejezőereje megegyezik

- azaz a nemdeterminizmus nem teszi erősebbé a modellt, csak kényelmesebb


- hatvány halmazkonstrukcióval történik

- DFA állapotai az NFA állapotainak részhalmazai lesznek
- ha az NFA 10 állapotú, a DFA-nak elméletben akár 2^{10} állapota is lehet

- a **nemdeterminisztikus ϵ -automaták** (epszilon) olyan véges automaták, ahol egy adott állapotból egy input szimbólum hatására akár több állapotba is átkerülhetünk, és megengedett az ϵ -átmenet azaz állapot-átmenet új szimbólum olvasása nélkül ("nem fogyasztja" az inputot)

- egy nyelv akkor és csak akkor ismerhető fel nemdeterminisztikus ϵ -automatóval, ha felismerhető nemdeterminisztikus automatóval

- ϵ -átmenet lényege:



$$L = \{(11)^*(00)^*(10)^*\}$$

Vagy másképp felírva, a szavak szerkezete: páros darab 1-es, utána páros darab 0-s, utána pedig tetszőleges számú 10 blokk.

- a szó végére érve nem áll le, hanem megnézi, hogy a jelenlegi állapot ϵ -lezártját, ami tartalmazza az összes ϵ -lépéssel elérhető állapotot onnan, ha van közöttük elfogadó állapot akkor elfogadja a szavat

- ha a szó feldolgozása közben érünk el ϵ -átmenetet ugyanúgy meglépjük, mint a választásos lépésnél és ezt is ugyanúgy folytatjuk, de input karaktert nem dobja el, nem vész el

Reguláris kifejezések (RegEx)

- a nyelvek algebrai leírására szolgálnak nemterminálisok és szabályok nélkül
 - **a nyelv elemeit szabályosan, ismétlődő minták szerint formázzák**
 - három alapműveletből építkeznek:
 - Unió (+ vagy $\cup$): „Vagy” kapcsolat (pl. $a + b$)
 - Konkatenáció: Összefűzés (pl. ab)
 - Kleene-csillag (*): Ismétlés tetszőleges (akár 0) alkalommal (pl. a^*)
 - $(ab)^*$ reguláris kifejezés azokat a szavakat írja le, amelyekben felváltva jelenik meg 'a' és 'b' betű. Tehát a "ab", "abab", "ababab" stb. szavak mind megfelelnek ennek a reguláris kifejezésnek
 - Prioritás (műveleti sorrend): iteráció > konkatenáció > unió
 - Kleene tétele: Egy nyelv akkor és csak akkor reguláris, ha leírható reguláris kifejezéssel és felismerhető véges automátával
 - ez azt jelenti, hogy a reguláris kifejezések, a véges automáták és a 3-as típusú nyelvtanok mind ugyanazt a nyelvcsaládot határozzák meg
 - gyakran használják szövegfeldolgozási feladatokban
 - reguláris kifejezések segítségével könnyen ellenőrizhető, hogy egy adott sztring megfelel-e egy adott nyelv szabályainak
 - reguláris kifejezésekkel megadott szűrők a szövegekben való keresésnél is hasznosak
-
- a^* ugyanaz, mint $(a)^*$ és az $\{a\}^*$ nyelvet reprezentálja,
 - $(a + b)^*$ ugyanaz, mint $((a) + (b))^*$ és a $\{a, b\}^*$ nyelvet reprezentálja,
 - $a^* \cdot b$ ugyanaz, mint $((a)^*) \cdot (b)$ és a $\{a\}^*b$ nyelvet reprezentálja,
 - $b + ab^*$ ugyanaz, mint $(b) + ((a) \cdot (b)^*)$ és a $\{b\} \cup \{a\}\{b\}^*$ nyelvet reprezentálja,
 - $(a + b) \cdot a^*$ ugyanaz, mint $((a) + (b)) \cdot ((a)^*)$ és a $\{a, b\}\{a\}^*$ nyelvet reprezentálja.

KÖRNYEZETFÜGGETLEN NYELVEK

A környezetfüggetlen nyelvek a programozási nyelvek szintaxisának leírására szolgálnak.


Környezetfüggetlen nyelvtanok (CF)

- $G = (N, \Sigma, P, S)$
 - N : nemterminálisok (A, B, S , stb) véges, nem üres halmaza
 - Σ abécé, mely a terminálisok (a, b, c, d) halmaza
 - P : levezetési, átírási szabályok (produkciós szabály) halmaza
 - a levezetési szabályok leírják, hogyan lehet a nemterminális szimbólumokat lecserélni terminális és/vagy más nemterminális szimbólumokra
 - szabály: $S \rightarrow aS \mid bS \mid a \mid b$
 $A \rightarrow \alpha$
 - egy szabály bal oldalán egy nemterminális, míg a jobb oldalán bármi állhat
 - ahol $A \in N$ (egyetlen nemterminális) és $\alpha \in (N \cup \Sigma)^*$ (bármilyen sorozat). A lényeg, hogy a bal oldalon álló A szimbólumot a **környezetétől függetlenül** bárhol lecserélhetjük a szabály jobb oldalára
 - pl "ab" megkapásához a kövi levezetés jár: $S \Rightarrow aS \Rightarrow ab$
 - S kezdő nemterminális, S eleme N -nek
- két környezet független nyelvtan akkor ekvivalens, ha ugyanazt a nyelvet generálja ($L(G) = L(G')$)
- $S \rightarrow aSb \mid \epsilon$ azaz $\{a^n b^n \mid n \geq 0\}$ fix környezetfüggetlen

Veremautomaták (Pushdown Automata - PDA)

- a CF nyelveket felismerő gép a veremautomata
- ez egy véges automata kiegészítve egy verem (stack) memóriával
 - minden környezetfüggetlen nyelvnek van vele ekvivalens veremautomatája és fordítva
 - egy nyelv akkor és csak akkor környezetfüggetlen, ha felismerhető (nemdeterminisztikus) veremautomatával
 - determinisztikus veremautomaták gyengébbek nem minden CF nyelvet ismernek fel, mert nem minden CF nyelv determinisztikus, csak az ami determinisztikus veremautomatával felismerhető
- $M = (Q, \Sigma, \Gamma, \delta, q_0, Z_0, F)$
 - Q : állapotok halmaza (nem üres, véges halmaz)
 - Σ : input abécé
 - Γ : verem abécé
 - ide pakoljuk a beérkező input betűket, stb
 - δ : egy átmenet függvény
 - $\delta(q_0, a, Z_0) = \{(q_1, aZ_0), (q_2, Z_0)\}$
 - $\delta(\text{állapot}, \text{input_karakter}, \text{verem_teteje}) = \{(\text{új_állapot}, \text{új_veremérték})\}$

- q_0 : kezdő állapot, eleme Q -nak
- Z_0 : kezdő szimbóluma a veremnek (verem alja jel)
- F : végállapotok halmaza, részhalmaza Q -nak
- működése
 - a gép a működése során egy lépésben állapotot vált és a verem tetejét, legfelső elemét kiolvassa, pop-olja ha az megfelel a kapott verem elemmel, majd pusholja helyére a kapott elemet, ha volt pop
 - ha nem volt pop-olás, mert nem egyezett a verem teteje az elvárt verem elemmel akkor azaz útvonal elhal, ha a többi, párhuzamosan futó ág közül egy eléri a végállapotot (vagy kiüríti a vermet), a gép még elfogadhatja a szót, de ez a specifikus ág nem folytatódhat
 - a nyelv elfogadása történhet végállapottal (szó végére F -beli állapotba jut) vagy üres veremmel (szó végére a verem kiürül)



Megjegyzés a képhez:

(input_karakter, verem_tetejeről_kivett_karakter, verembe_rakott_karakter)

első lépést akkor hatja végre ha a a bemeneti karakter a

ϵ , epszilon = üres szó (jflapba ez lambda lenne λ)

Z_0 = speciális jel, szimbólum mely a verem alját jelenti üres verem esetén

PUMPÁLÓ LEMMÁK

- ezekkel bizonyítható be, egy nyelvről, hogy nem tartozik egy adott osztályba (pl. nem reguláris vagy nem környezetfüggetlen)
 - ellentpéldát ad

Reguláris nyelvekre vonatkozó pumpáló lemma

- ha egy nyelv környezetfüggetlen, de nem reguláris akkor a (sima) pumpáló lemma feltételeit nem teljesíti, azaz egyfajta ellenpélda áll elő
 - ez kimutatja, hogy nem minden környezetfüggetlen nyelv reguláris nyelv
- a lemma egy **szükséges, de nem elégséges feltétel**, tehát lehetnek nem reguláris nyelvek, amikre véletlenül igaz a lemma
 - de ha a lemma **nem teljesül**, akkor a **nyelv biztosan nem reguláris**
- ha L reguláris, akkor létezik egy k (vagy p) küszöbszám és minden $w \in L$ szóra, ha $|w| \geq k$, akkor a szó felbontható három részre: $w = xyz$, úgy, hogy:
 1. $|y| \geq 1$ (a pumpálható rész nem üres, tehát van mint pumpálni)
 2. $|xy| \leq k$
 - a pumpálás a szó elejéhez közel, az első k karakteren belül történik
 - ez garantálja, hogy az ismétlődés (hurok) már az automata első k állapotátmenete során megtörténik
 - enélkül nem tudnánk pontosan hol keresni az y -t, azaz y milyen betűket tartalmaz
 3. minden $i \geq 0$ esetén $xy^iz \in L$ (a középső rész ismételhető)
 - $i = 0$ eset: ezt hívjuk "lefelé pumpálásnak", ekkor egyszerűen kihagyjuk az y részt (a lemmának erre is igaznak kell lennie)
- konyhanyelven, tehát ha van egy reguláris nyelv akkor létezik egy olyan minimális hossz (k), amely fölött minden szó úgy van felépítve, hogy van egy középső része (y), mely tetszőleges számban ismételhető (pumpálható) és a kapott szó még mindig a nyelv része marad
- a lemma a **skatulya elven** alapul
 - ha egy véges automatának k darab állapota van, és egy legalább k hosszú szót olvas be, akkor az automata összesen $k+1$ állapotot érint
 - mivel csak k különböző állapota van, legalább egy állapotba kétszer is be kell lépnie, ez az ismétlődés egy kört alkot az automatában
 - ez a hurok az y rész, mivel ez egy hurok, az automata bárhányszor körbe tud menni rajta, mielőtt továbblépne az elfogadó állapot felé

- Példák, az $L = \{ a^n b^n \mid n \geq 0 \}$ nem reguláris nyelvre
 - ha $w = a^k b^k$, akkor a lemmának megfelelően az y rész csak a -kat tartalmazhat (hossza $2 \cdot k$ lesz, és tudjuk, hogy xy hossza kisebb vagy egyenlő k)
 - ha pumpáljuk, a szóban több a lesz mint b , így kilépünk a nyelvből, tehát L nem reguláris
 - tegyük fel, hogy a pumpálási hosszunk $k = 4$, a választott szavunk a nyelvből: $w = a^4 b^4$, azaz: **$w = aaaa bbbb$**
 - a lemma szerint ezt a szót kell felbontanunk xyz részekre úgy, hogy az eleje (x , y) hossza legfeljebb $k = 4$ legyen, a pumpált rész y nem üres. Nézzük a legjellemzőbb eseteket:

1. A pumpált rész csak egyféle betűt tartalmaz

- tegyük fel, felbontásunk olyan, hogy az y részbe csak egyetlen 'a' jutott
 - $x = aa$
 - $y = a$ ($|xy| = |aaa| = 3$ ami ≤ 4)
 - $z = a bbbb$
- eredeti szó ($i=1$): $xy^1z = aa(a)a bbbb = aaaa bbbb$
 - ez benne van L -ben
- pumpálás felfelé ($i=2$) $xy^2z = aaaaa bbbb = aaaaa bbbb$
 - a -k száma 5
 - b -k száma 4
 - eredmény $\rightarrow a^5 b^4$ nincs benne L -ben
- pumpálás lefelé ($i=0$) $xy^0z = aa abbbb$
 - a -k száma 3
 - b -k száma 4
 - Eredmény $\rightarrow a^3 b^4$ nincs benne L -ben

2. A pumpált rész több betűt tartalmaz

- nézzünk egy olyan felbontást, ahol az y rész hosszabb, de még mindig az első 4 karakteren belül van
 - $x = a$
 - $y = aaa$ ($|xy| = |a aaa| = 4$ ami ≤ 4 és $|y| \geq 1$)
 - $z = bbbb$
- Pumpálás felfelé ($i=2$): $xy^2z = a(aaaaa) bbbb = aaaaaa bbbb$
 - a -k száma 7
 - b -k száma 4
 - Eredmény $\rightarrow a^7 b^4$ nincs benne L -ben

Környezetfüggetlen nyelvekre vonatkozó pumpáló lemma (Bar-Hillel Lemma)

- minden L környezetfüggetlen nyelvhez létezik egy k (vagy p) küszöbszám, hogy minden $w \in L$, $|w| \geq k$ szó felosztható 5 részre: $w = uvxyz$, úgy, hogy:
 - $|vy| \geq 1$: v és y közül legalább az egyik nem üres szó (ϵ)
 - $|vxy| \leq k$: a pumpált rész és a közte lévő rész korlátos
 - minden $i \geq 0$ esetén $u v^i x y^i z \in L$
 - v -t és y -t szimmetrikusan pumpáljuk
- konyhanyelven, tehát ha van egy környezetfüggetlen nyelv akkor létezik egy olyan minimális hossz (k), amely fölött minden szó úgy van felépítve, hogy van egy középső része (vxy), mely tetszőleges számban ismételhető (pumpálható) és a kapott szavak még mindig a nyelv részei maradnak
- a Bar-Hillel lemma a levezetési fa magasságán alapul
 - ha egy szó elég hosszú, akkor a levezetési fája olyan magas lesz, hogy a leghosszabb úton egy nemterminális szimbólum legalább kétszer előfordul, tehát meg kell, hogy ismétlődjön
 - az első A alatt helyezkedő részfa generálja a vxy részt
 - a második lejjebb lévő A alatt elhelyezkedő részfa generálja az x részt.
 - az a terület, ami az első és a második A között van generálja a v és y részeket
 - mivel az A szimbólum önmagát is le tudja vezetni ($A \Rightarrow^* vAy$), ez a folyamat tetszőlegesen sokszor megismételhető
- Példák, az $L = \{a^n b^n c^n\}$ nyelv nem környezetfüggetlenségének bizonyítására
 - tegyük fel, hogy a pumpálási hosszunk $k = 4$. A választott szavunk a nyelvből: $w = a^4 b^4 c^4$, azaz: $w = \mathbf{aaaa\ bbbb\ cccc}$
 - a lemma szerint ezt a szót kell felbontanunk $uvxyz$ részekre úgy, hogy a középső rész (vxy) hossza legfeljebb $k = 4$ legyen. Nézzük a legjellemzőbb eseteket:

1. A pumpált rész csak egyféle betűt tartalmaz

- tegyük fel, hogy a felbontásunk olyan, hogy a v és y részekbe csak a betűk jutottak (mivel a vxy hossza korlátos, ez gyakori eset)
 - $u = a$
 - $v = a$
 - $x = a$
 - $y = a$ ($|vxy| = |aaa| = 3$ ami ≤ 4)
 - $z = \mathbf{bbbb\ cccc}$
- eredeti szó ($i = 1$): $uv^1xy^1z = a(a)a(a) \mathbf{bbbb\ cccc} = \mathbf{aaaa\ bbbb\ cccc}$, ez benne van L -ben
- pumpálás felfelé ($i = 2$): $uv^2xy^2z = a(aa)a(aa) \mathbf{bbbb\ cccc} = \mathbf{aaaaaa\ bbbb\ cccc}$
 - a -k száma 6
 - b -k száma 4
 - c -k száma 4
 - Eredmény $\rightarrow a^6 b^4 c^4$ nincs benne L -ben

2. A pumpált rész kétféle betűt tartalmaz

- Mivel $vxy \leq 4$, a vxy szakasz átnyúlhat például az a és b betűk határán
 - $u = aaa$
 - $v = a$
 - $x = \varepsilon$ (üres szó)
 - $y = b$ ($|vxy| = |ab| = 2$ ami ≤ 4)
 - $z = bbb cccc$
- pumpálás felfelé ($i = 2$): $uv^2xy^2z = aaa(aa)(bb) bbb cccc$
 - a -k száma 5
 - b -k száma 5
 - c -k száma 4
 - Eredmény $\rightarrow a^5b^5c^4$ nincs benne L -ben
- Pumpálás lefelé ($i = 0$) $uv^0xy^0z = aaa bbb cccc$
 - a -k száma 3
 - b -k száma 3
 - c -k száma 4
 - Eredmény $\rightarrow a^3b^3c^4$ nincs benne L -ben
- Nem lehetne úgy választani az $uvxyz$ -t, hogy mindháromból ugyanannyit pumpáljunk?
 - NEM. Ahhoz, hogy a v -ben és y -ban legyen a , b , c is, a vxy résznek az első a -tól az utolsó c -ig el kellene érnie. Tegyük fel a szavunk: $aaaa bbbb cccc$. Az első a és az utolsó c között a távolság 12 karakter. De a szabály kimondja hogy vxy legfeljebb k lehet, ami a mi példánkban 4
 - Ha k értékét megnöveljük, két dolog történik: egyrészt választhatok egy hosszabb szót ($a^k b^k c^k$), amivel a korábbi bizonyítás ugyanúgy működik. Másrészt, még ha a vxy át is érné a teljes szót, akkor is csak 2 helyen (v és y) tudunk pumpálni. Mivel 3 betűtípus van, de csak 2 pumpálási hely, vagy valamelyik betű kimarad a növelésből (és felborul az $n=n=n$ arány), vagy ha egy pumpált részbe kétféle betűt is teszünk, akkor a pumpálás után felborul a betűk sorrendje. Így a nyelv semmiképp nem lehet környezetfüggetlen.

ZÁRTSÁGI TULAJDONSÁGOK MŰVELETEKRE

- formális nyelvek egyik legfontosabb jellemzője
- egy adott nyelvosztály zárt egy bizonyos művelet alatt, ha a nyelvosztály elemeire (nyelv) alkalmazzuk az adott műveletet akkor az eredménye is az adott nyelvosztályba tartozik
 - lehetővé teszi, hogy a nyelvet alkotó elemekkel új elemeket hozzunk létre anélkül, hogy a nyelv jellemzői megváltoznának
- **Unió:** két nyelv uniója olyan szavakból áll, amelyek legalább az egyik nyelvbe benne vannak
- **Metszet:** olyan szavak halmaza, amelyek mindkét nyelvben szerepelnek
 - környezetfüggetlen nyelvek esetén erre nemzárt, mivel verem automata esetén ilyenkor már 2 verem kellene ahhoz, hogy a két külön feltételt (egyik ebből másik a másik nyelvből jön) ellenőrizni
- **Komplementer (kiegészítő halmaz, jele a felülvonás):** egy nyelv komplementere az összes olyan szó az adott ábécé felett, amely nincs benne az eredeti nyelvben:

$$P' = \Sigma^* - L$$
 - környezetfüggetlen nyelvek erre nemzártak, mivel a metszetre se zártak, ezért a De Morgan azonosság miatt jól kikövetkeztethető: $L_1 \cap L_2 = \overline{\overline{L_1} \cup \overline{L_2}}$
 - amiatt mondható így ki mivel tudjuk, hogy Unióra zártak, tehát ha komplementerre is zártak lennének akkor L_1 és L_2 komplementere is környezetfüggetlen lenne és Unió zárt, tehát az is környezetfüggetlen akkor ennek a komplementere is környezetfüggetlen lenne, ez meg egyenlő a metszettel, ami meg tudjuk, hogy nem zár
- **Konkatenáció:** Az L_1 L_2 nyelvek konkatenációja során veszünk egy szót L_1 -ből, majd egyet az L_2 -ből és konkatenáljuk őket $w = xy$, ahol x eleme L_1 , míg y eleme L_2
- **Kleene-csillag (*, iteráció vagy lezárás):** egy nyelv szavainak tetszőleges számú (akár 0-szoros, azaz üresszó) egymás után fűzésével kapott szavak halmaza (összes lehetséges kombináció)
- **Homomorfizmus:** egy olyan függvény, amely a nyelv ábécéjének minden egyes betűjét lecseréli egy-egy meghatározott szóra, ha a nyelv összes szavában végrehajtjuk ezt a cserét, megkapjuk a homomorf képét
- **Inverz homomorfizmus:** a homomorfizmus folyamat visszafele, azaz azokat a szavakat keressük, amelyeket ha a homomorfizmussal átalakítanánk, a kiindulási nyelvünkbe eső szót kapnánk

Művelet	Zártság	Zártság
	CF	DCF
$\cup$	igen	nem
konkatenáció	igen	nem
*	igen	nem
$\cap$	nem	nem
$\cap$ reg. nyelv	igen	igen
komplementer	nem	igen

Művelet	Reguláris nyelvek	Környezetfüggetlen nyelvek
Unió	x	x
Metszet	x	
Komplementer	x	
Konkatenáció	x	x
Kleene-csillag	x	x
Homomorfizmus	x	x
Inverz homomorfizmus	x	x